

Conception d'une ontologie pour le Home Cage Monitoring : structuration, interopérabilité et réutilisation des données

Cyril GILBERT

16 juin 2026

Table des matières

1	Introduction	2
2	Contexte scientifique : le Home Cage Monitoring	3
3	Ontologies, Web sémantique et structuration des données	5
3.1	Fondements du Web sémantique	5
3.2	Méthodologies de conception	7
3.3	Rôle des modèles de langage et des graphes de connaissances .	7
3.4	Bonnes pratiques et outillage	9
3.5	Pourquoi aller jusqu'à une ontologie ?	10
4	Travail réalisé pendant le stage	11
4.1	Analyse du domaine HCM	11
4.2	Identification des concepts principaux	12
4.3	Méthode de construction	13
4.4	Caractéristiques de HCMO et usages prévus	14
4.5	Construction de l'ontologie	15
4.6	Description des classes et relations	16
5	Discussion et perspectives	20

1 Introduction

En recherche préclinique, les tests comportementaux servent à étudier comment un animal réagit dans une situation donnée. Ils peuvent être utilisés pour caractériser un modèle de pathologie, évaluer l’effet d’un traitement ou repérer des changements comportementaux liés à un état physiologique ou expérimental. Ces tests occupent alors une place importante dans l’interprétation des modèles animaux.

La recherche préclinique utilise encore beaucoup de tests comportementaux courts chez les rongeurs. Ces tests sont souvent réalisés en dehors de la cage de vie de l’animal, dans un environnement nouveau. Cela peut introduire du stress et modifier les comportements observés.

Ces tests donnent aussi une vision limitée de la réelle activité de l’animal. Ils durent souvent peu de temps et sont fréquemment réalisés pendant la journée, alors que les rongeurs sont plus actifs pendant la phase nocturne. Ces limites peuvent contribuer à la variabilité des résultats entre différentes expériences ou entre laboratoires.

Dans ce contexte, le Home Cage Monitoring propose une autre approche. L’idée n’est plus d’amener l’animal vers le test, mais d’apporter l’observation dans son environnement habituel. Grâce à des capteurs, du matériel et des logiciels, il devient possible de suivre l’animal sur de longues périodes, avec une intervention humaine plus limitée.

On obtient ainsi des données plus régulières et mieux replacées dans leur contexte. Elle peut aussi contribuer aux principes des 3R (remplacement, réduction et raffinement), surtout le raffinement. On limiterait certaines manipulations directes et certains facteurs de stress liés à la manipulation.

Cependant, la diversité des systèmes, des capteurs, des variables mesurées et de ces métadonnées nécessite une structuration plus formelle. Mon stage s’inscrit dans cette problématique, à partir des travaux encadrés par Damien Huzard et de l’état de l’art sur les ontologies et le Home Cage Monitoring. L’objectif a donc été de proposer une première ontologie capable de représenter les concepts clés du domaine ainsi que leurs relations. On souhaite faciliter la réutilisation, l’interopérabilité et la mise en conformité avec les principes FAIR (*Findable, Accessible, Interoperable and Reusable*).

Au-delà de la réutilisation des données, cette structuration est aussi importante pour des usages liés à l’intelligence artificielle. Les données HCM peuvent être vues comme un futur graphe de connaissances, dans lequel les animaux, les cages, les capteurs, les observations, les mesures et les métadonnées sont reliés explicitement. Une telle représentation peut ensuite servir de base à des requêtes, à du raisonnement, ou à des méthodes d’apprentissage sur graphes, comme les embeddings de graphes de connaissances. C’est aussi

dans cette perspective que les échanges avec Konstantin Todorov ont été importants, en raison de ses travaux sur les graphes de connaissances et leur exploitation par des méthodes d'apprentissage [2].

Construire une ontologie ne consiste donc pas seulement à dessiner un plan de données. Il s'agit plutôt de définir précisément le sens des concepts manipulés, les relations et les règles permettant à une machine d'interpréter ces connaissances. Contrairement à une base de données classique, qui stockerait principalement des valeurs dans des tables, une ontologie chercherait à formaliser un domaine. On améliore ainsi la possibilité d'inférence, la vérification de cohérence et la réutilisation des connaissances [14].

Ce rapport présente donc un état intermédiaire du travail : il ne s'agit pas encore d'une ontologie finalisée, mais d'une première structuration du domaine, construite à partir de lectures, d'échanges avec l'équipe encadrante et d'essais de modélisation.

2 Contexte scientifique : le Home Cage Monitoring

Les méthodes classiques de phénotypage comportemental chez les rongeurs reposent souvent sur des tests courts, réalisés en dehors de la cage de vie de l'animal. Les approches traditionnelles impliquent fréquemment le transfert physique de l'animal vers une nouvelle zone de test, avec une observation limitée dans le temps [12]. Ces conditions peuvent réduire la capacité à observer les rythmes circadiens (cycle de 24h), les comportements spontanés et les changements assez subtils apparaissant plus clairement sur de longues périodes.

Ces tests, comme l'open field ou certains labyrinthes, restent utiles pour étudier des comportements ciblés. Cependant, ils ne représentent qu'une fenêtre limitée de l'activité réelle de l'animal. Le déplacement vers un nouvel environnement et les manipulations humaines peuvent aussi introduire du stress ou des biais comportementaux, ce qui peut compliquer l'interprétation des résultats [12].

Le Home Cage Monitoring répond à ces limites en inversant la logique expérimentale : au lieu d'amener l'animal vers le test, le dispositif d'observation est intégré à son environnement habituel. Un système HCM collecte des informations sur un animal vivant dans un espace qui fournit notamment de la nourriture, de l'eau, des contacts sociaux, et de la sécurité [12]. Le système associe alors un environnement de vie, du matériel, des capteurs, parfois des actionneurs, et des logiciels d'acquisition ou d'analyse.

Cette définition met en évidence que le HCM ne se limite pas à un seul capteur isolé : c'est un système complet, combinant en résumé l'animal, son environnement, le matériel d'acquisition et les logiciels d'analyse.




FIGURE 1 – Définition conceptuelle du Home Cage Monitoring selon le modèle Olog, d'après [12].

La figure 1 synthétise cette définition. Cette approche permet d'obtenir des données parfois sur plusieurs jours ou semaines, et de capturer ces comportements spontanés, les rythmes circadiens, des micro-variations d'activité ou des signes précoces de pathologie. C'est aussi un intérêt éthique, car on limite les manipulations directes, réduit le stress et contribue aux principes des 3R, surtout pour le raffinement et potentiellement la réduction du nombre d'animaux nécessaires.

Il faut cependant éviter de présenter le HCM comme une solution automatiquement supérieure aux tests classiques. Cette approche apporte des avantages importants, mais elle possède aussi ses propres limites. Les résultats dépendent fortement du type de capteur utilisé, de la qualité du logiciel d'analyse, de la définition des variables mesurées et de la documentation du contexte expérimental. Le HCM ne supprime donc pas les biais méthodologiques : il en déplace une partie vers les choix techniques, les algorithmes d'interprétation et la qualité des métadonnées.




FIGURE 2 – Exemples de paramètres comportementaux et physiologiques mesurables en Home Cage Monitoring, d’après [12].

La figure 2 illustre la diversité des paramètres comportementaux et physiologiques pouvant être suivis en HCM. Cette richesse de données crée alors aussi de nouvelles difficultés. Les systèmes HCM peuvent varier fortement : capteurs, logiciels, espèces suivies, paramètres mesurés ou formats produits. Cette hétérogénéité complique alors la comparaison des expériences, la réutilisation des données et leur intégration dans des approches d’analyse plus larges. C’est dans ce contexte que la structuration des données au moyen d’une ontologie devient pertinente : elle permet de relier les mesures produites à leur contexte expérimental, technique et biologique.

3 Ontologies, Web sémantique et structuration des données

3.1 Fondements du Web sémantique

Le Web sémantique vise à rendre les données plus compréhensibles et exploitables par les machines. Il repose sur une architecture en couches, dans

laquelle chaque niveau apporte un rôle particulier. À la base, les URI permettent d'identifier de manière unique les ressources. Dans le cas d'une ontologie, cela signifie qu'une classe, une propriété ou une entité peut recevoir un identifiant stable et réutilisable.

RDF constitue ensuite le modèle de représentation de base. Il décrit l'information sous forme de triplets : un sujet, un prédicat et un objet. Ces triplets forment un graphe, où les éléments du domaine sont reliés entre eux. Par exemple, un animal peut être relié à une cage, une cage à un système HCM, et un capteur à une observation. RDF peut être sérialisé dans plusieurs formats, comme RDF/XML ou Turtle. Dans ce stage, Turtle a été privilégié comme format cible, car il est plus lisible pour vérifier manuellement la structure générée.

RDFS permet d'ajouter une première couche de sémantique au graphe RDF. Il permet notamment de définir des classes, des sous-classes, des propriétés, ainsi que le domaine et la portée de ces propriétés. OWL va plus loin en permettant de représenter des contraintes plus riches, par exemple des restrictions sur les propriétés, des équivalences entre classes ou des relations logiques plus précises. Ces éléments peuvent ensuite être utilisés par des raisonneurs [5], c'est-à-dire des logiciels capables de vérifier la cohérence logique d'une ontologie et d'en déduire de nouvelles informations.

Enfin, SPARQL permet d'interroger les graphes RDF. Il joue un rôle important dans l'utilisation pratique des ontologies, car il permet de formuler des requêtes sur les classes, les relations et les instances représentées dans le graphe. Dans le contexte de HCMO, SPARQL pourrait par exemple servir à retrouver les capteurs associés à une cage, les observations produites par un dispositif, ou les mesures ne possédant pas d'unité.




FIGURE 3 – Architecture simplifiée du Web sémantique, inspirée de la pile du Web sémantique.

Cette architecture est importante pour HCMO, car l'objectif n'est pas seulement de produire un schéma visuel. Le modèle doit pouvoir être trans-

formé en une représentation exploitable par des outils du Web sémantique : des identifiants pour les concepts, des triplets RDF pour les relations, des classes et propriétés OWL pour structurer le domaine, puis des requêtes SPARQL pour interroger les données.

3.2 Méthodologies de conception

Une ontologie se construit rarement en une seule fois. Le travail commence généralement par l'identification des besoins du domaine. Ces besoins peuvent être formulés sous forme de questions de compétence, c'est-à-dire des questions auxquelles l'ontologie devrait pouvoir répondre [14, 17].

Les méthodes récentes, comme SAMOD ou LOT, proposent une construction progressive. L'ontologie est enrichie par étapes, testée, puis corrigée si nécessaire [15, 17]. Cette logique itérative convient bien à un domaine comme le HCM, où les concepts sont nombreux et parfois difficiles à stabiliser.

3.3 Rôle des modèles de langage et des graphes de connaissances

Les grands modèles de langage peuvent aider certaines étapes de l'ingénierie ontologique. Ils peuvent par exemple proposer des concepts, reformuler des questions de compétence ou aider à organiser un premier modèle. Ils peuvent aussi être utilisés pour extraire des éléments structurés à partir de textes ou de données non structurées.

On peut distinguer deux usages. Dans une approche Top-Down, le modèle aide l'expert, mais l'expert garde le contrôle. Dans une approche Bottom-Up, le modèle extrait directement des éléments depuis les données pour proposer une structure, souvent dans un contexte de génération augmentée par récupération (*Retrieval-Augmented Generation*, RAG), où le modèle s'appuie sur des documents ou des données externes [1, 3, 8].

Pour HCMO, l'IA n'intervient pas seulement comme une aide à la construction de l'ontologie. L'ontologie peut aussi servir à structurer l'usage futur de l'IA. En imposant des classes, des relations et des contraintes explicites, elle permet d'éviter que les traitements automatiques reposent uniquement sur des associations statistiques difficiles à interpréter.

HCMO peut ainsi être vue comme une base pour construire un graphe de connaissances HCM.




FIGURE 4 – Exemple de pipeline d’interrogation d’un graphe de connaissances avec un modèle de langage : la question de l’utilisateur est transformée en requête Cypher, exécutée dans Neo4j, puis les résultats sont reformulés en langage naturel. Schéma fourni par Gaoussou Sanou.

Cet exemple montre concrètement comment un modèle de langage peut interroger un graphe de connaissances. Dans l’exemple présenté en figure 4, une question formulée en langage naturel est transformée en requête Cypher par un module LangChain, puis exécutée sur une base Neo4j. Les résultats du graphe sont ensuite convertis en réponse textuelle. Le modèle de langage n’interroge pas des données brutes, mais s’appuie sur un graphe explicite, dont les entités et les relations sont définies en amont.

Ce graphe pourrait ensuite être interrogé par des requêtes SPARQL, exploité par des méthodes de raisonnement symbolique, ou utilisé dans des approches d’apprentissage sur graphes. Les embeddings de graphes de connaissances permettent par exemple de représenter des entités et des relations dans un espace vectoriel afin d’explorer des similarités, de prédire des liens manquants ou d’identifier des profils récurrents. Des travaux récents sur les graphes de connaissances biomédicaux et les embeddings montrent aussi l’intérêt de ces représentations pour explorer des relations entre entités et soutenir certaines tâches prédictives [19].

Un autre usage consiste à exploiter directement la structure hiérarchique d’une ontologie dans un modèle prédictif. Dans ses travaux sur la prédiction des fonctions protéiques, Antoine Toffano utilise la Gene Ontology pour représenter de manière standardisée les fonctions associées aux protéines ainsi que leurs dépendances hiérarchiques [2]. Le modèle ne cherche alors pas seule-

ment à prédire des étiquettes indépendantes : il prend en compte le fait qu’une fonction biologique générale peut englober des fonctions plus spécifiques. Cette organisation permet de produire des prédictions plus cohérentes avec la structure des connaissances biologiques et plus facilement interprétables.




FIGURE 5 – Comparaison entre des fonctions prédites et les annotations hiérarchiques réelles. La structure de la Gene Ontology permet d’évaluer si les prédictions respectent les dépendances entre fonctions biologiques générales et spécifiques. Schéma fourni par Antoine Toffano.

Ces approches doivent être utilisées avec prudence. Elles peuvent proposer des relations fausses ou trop générales. Une validation humaine reste nécessaire, en particulier lorsque l’ontologie sert ensuite de base à des traitements automatiques.

3.4 Bonnes pratiques et outillage

Des outils spécialisés aident à construire et vérifier une ontologie. Protégé permet de créer des classes, des propriétés et des axiomes OWL. Il peut aussi être utilisé avec des raisonneurs [20, 10].

D’autres outils interviennent après la modélisation. WIDOCO aide à produire une documentation lisible [9]. OOPS! permet de repérer certains problèmes fréquents, comme des classes mal décrites ou des relations ambiguës [18]. Ces outils sont utiles pour améliorer progressivement la qualité du modèle.

3.5 Pourquoi aller jusqu'à une ontologie ?

Avant de construire une ontologie, plusieurs niveaux de structuration des données peuvent être envisagés. Un vocabulaire contrôlé permet d'éviter les variations de langage en imposant des termes communs. Une taxonomie organise ces termes dans une hiérarchie simple. Un thésaurus va plus loin qu'une simple liste de termes : il indique des relations de vocabulaire, par exemple les synonymes, les termes plus généraux ou les termes associés. Enfin, un standard de métadonnées, éventuellement exprimé en JSON, permet de préciser les informations attendues dans un format structuré et réutilisable.

Ces approches sont utiles, mais elles restent limitées lorsqu'il s'agit de représenter un domaine complexe comme le Home Cage Monitoring. Les données HCM ne décrivent pas seulement des mesures isolées : elles relient un animal, une cage, un système de capteurs, un protocole expérimental, des conditions environnementales, des comportements observés et des métadonnées de provenance. L'interopérabilité en HCM nécessite à la fois des vocabulaires communs et des ontologies partagées, capables de relier les comportements, les mesures physiologiques et les conditions expérimentales dans une couche sémantique exploitable par des machines [7].

L'intérêt d'une ontologie est donc d'aller au-delà de la simple normalisation des mots. Elle permet de formaliser les concepts du domaine, de préciser leurs relations, de réutiliser des identifiants existants et de rendre les données plus facilement interrogeables, comparables et intégrables. Dans le contexte de la recherche préclinique, cette structuration rejoint aussi les enjeux FAIR : les données doivent être trouvables, accessibles, interopérables et réutilisables. L'approche WellFAIR insiste sur le fait que la qualité des données est également un enjeu éthique, car les données constituent le résultat durable de l'expérimentation animale [16].




FIGURE 6 – Écosystème WellFAIR reliant préparation des métadonnées, acquisition, fédération et réutilisation des données, d'après [16].

La figure 6 illustre ce cycle de préparation, d’acquisition et de réutilisation des données. Dans ce stage, le choix d’une ontologie répond donc à ce besoin précis : proposer un modèle capable de représenter non seulement les objets du domaine HCM, mais aussi les relations qui les rendent interprétables. L’objectif n’était pas de produire seulement une liste de termes ou un format de fichier, mais une structure conceptuelle pouvant servir de base à la documentation, à la réutilisation et à l’intégration future des données.

4 Travail réalisé pendant le stage

4.1 Analyse du domaine HCM

L’analyse du domaine HCM a constitué une étape centrale du travail. Avant de modéliser les classes et les relations de l’ontologie, il était nécessaire de clarifier les objets, les pratiques et les besoins scientifiques associés au Home Cage Monitoring. On souhaitait identifier les notions récurrentes du domaine : l’animal observé, son environnement de vie, les dispositifs matériels, les capteurs, les logiciels, les mesures produites, les comportements observés et les métadonnées nécessaires à l’interprétation des données.

Le HCM se distingue des tests comportementaux classiques par le fait qu’il ne repose pas uniquement sur une observation ponctuelle, mais sur une acquisition continue ou répétée dans l’environnement habituel de l’animal. Cette particularité modifie fortement les besoins de description. Il ne suffit pas de savoir qu’une mesure a été produite : il faut également pouvoir décrire dans quelles conditions elle a été obtenue, avec quel système, sur quel animal, dans quelle cage, avec quels paramètres environnementaux, à quel moment et selon quel protocole. L’analyse du domaine a donc rapidement montré que les données HCM sont inséparables de leur contexte expérimental.

Une difficulté importante vient aussi de la diversité des systèmes HCM. Certains dispositifs reposent sur de la vidéo, d’autres sur de la RFID, des capteurs infrarouges, des capteurs de mouvement, des dispositifs de suivi de l’alimentation ou de la consommation d’eau, ou encore des combinaisons de plusieurs technologies. Les systèmes peuvent être commerciaux, construits en laboratoire ou hybrides [11, 6]. Cette diversité est une richesse scientifique, car elle permet d’adapter les dispositifs à différentes questions expérimentales, mais elle complique aussi la comparaison et la réutilisation des données. Deux expériences peuvent mesurer des comportements proches tout en utilisant des capteurs, des formats et des paramètres très différents.

Cette phase d’analyse a également fait apparaître l’importance des métadonnées. Dans le contexte du HCM, les métadonnées ne sont pas de simples

informations secondaires ajoutées après l'expérience. Elles conditionnent la compréhension même des données produites : espèce, souche, sexe, âge, conditions d'hébergement, enrichissement, configuration de la cage, type de capteur, fréquence d'acquisition, logiciel utilisé, protocole expérimental ou encore traitement appliqué aux données. Sans ces éléments, une mesure comportementale ou physiologique peut devenir difficile à interpréter, à comparer ou à réutiliser.

À partir de cette analyse, le domaine HCM a été considéré comme un ensemble de relations plutôt que comme une simple liste d'objets. Un animal vit dans un environnement donné, un système observe cet environnement, un capteur produit une mesure, une mesure porte sur un comportement ou une variable physiologique, et l'ensemble s'inscrit dans un protocole expérimental. Cette vision relationnelle justifie le recours à une ontologie : elle permet de représenter les entités du domaine, mais surtout les liens qui donnent ce sens aux données.

4.2 Identification des concepts principaux

L'identification des concepts principaux a consisté à transformer les éléments observés dans la littérature et les échanges de stage en catégories ontologiques. Pour rendre cette organisation plus lisible, les concepts ont été regroupés en quatre familles principales, qui correspondent aux modules utilisés dans HCMO. Cette correspondance permet de garder le même ordre de lecture entre l'analyse du domaine, la présentation des concepts et les figures du modèle : HCMO-bio, HCMO-housing, HCMO-env et HCMO-tech.

La première famille, HCMO-bio, concerne le sujet animal et les observations biologiques. L'animal constitue l'objet central de l'observation, mais il ne peut pas être décrit de manière isolée. Il doit être associé à des informations comme l'espèce, la souche, le sexe, l'âge, le génotype ou encore certains éléments nécessaires à l'interprétation des observations de poids, de santé ou de comportement.

La deuxième famille, HCMO-housing, concerne l'hébergement et le contexte expérimental. Elle regroupe la cage, l'assignation de l'animal à un environnement, les groupes expérimentaux et certains facteurs d'étude. Cette partie est importante car les données HCM dépendent fortement du lieu de vie de l'animal et des conditions dans lesquelles il est suivi.

La troisième famille, HCMO-env, concerne les conditions environnementales. Elle permet de représenter les dimensions de la cage, l'enrichissement, les cycles lumineux, les profils de gaz et certaines propriétés mesurables comme la température, l'humidité ou l'intensité lumineuse. Ces informations ne sont pas secondaires : elles participent directement à l'interprétation des

mesures produites.

La quatrième famille, HCMO-tech, concerne les dispositifs techniques. Elle regroupe le matériel, les capteurs, les logiciels, les séries temporelles et les objets de données produits. Les besoins de monitoring peuvent mobiliser différentes technologies, comme la vidéo, la RFID, les capteurs infrarouges, les capteurs de mouvement, les barrières de passage, les capteurs de poids ou encore des dispositifs permettant de mesurer certains signaux physiologiques [11].

Ce découpage permet d'éviter de mélanger des éléments de nature différente : l'animal observé, l'environnement dans lequel il vit, le capteur qui produit une observation, le logiciel qui transforme les données, et les métadonnées qui documentent le contexte de production. Il permet aussi de garder une cohérence entre les familles de concepts et les vues graphiques de l'ontologie présentées ensuite.

4.3 Méthode de construction

La construction de HCMO a d'abord commencé par une phase d'exploration des formats possibles. Une première piste a été envisagée avec LinkML et une représentation en YAML, afin de décrire les classes et les propriétés dans un format structuré [13]. Un tableau de travail a ensuite été utilisé pour lister les concepts, les propriétés, les types attendus et les relations importantes.

Dans un second temps, le travail s'est orienté vers Chowlk, un outil permettant de transformer une conceptualisation graphique réalisée avec diagrams.net en une représentation OWL, notamment sérialisée en Turtle [4]. Ce choix permettait de représenter graphiquement l'ontologie tout en conservant une structure convertible vers des formats du Web sémantique. Cette approche était adaptée à une V1, car elle rendait le modèle plus facile à discuter avec les experts du domaine.

Les outils présentés dans l'état de l'art n'ont donc pas tous été utilisés au même moment ni pour le même objectif. Protégé reste pertinent pour explorer la structure OWL et vérifier certaines propriétés du modèle. WIDOCO et OOPS! sont plutôt envisagés pour les étapes de documentation et de contrôle qualité. En revanche, Chowlk a été privilégié pour la phase actuelle, car il permettait de construire une représentation graphique lisible, plus facile à discuter avec les experts du domaine, tout en conservant une possibilité de conversion vers OWL/Turtle.

Pour guider la stabilisation du modèle, des questions de compétence ont été utilisées. Elles permettent de vérifier que l'ontologie ne décrit pas seulement des classes isolées, mais qu'elle peut répondre à des besoins concrets du domaine. Ces questions couvrent plusieurs axes : l'assignation des animaux

aux cages, les groupes expérimentaux, les observations de poids ou de comportement, les conditions environnementales, la provenance des mesures et la qualité des métadonnées.

Parmi les questions utilisées, on peut citer par exemple :

- Which enclosure is Subject_001 assigned to at time T ?
- Which subjects are currently housed in Room_101 ?
- What is the latest recorded weight of Subject_001 ?
- Which subjects were exposed to temperature above 25°C ?
- Which sensors monitor Enclosure_A2 ?
- Are there observations with numeric values but no units ?

Ces questions ont servi de repères pendant la modélisation. Une partie importante d'entre elles peut être représentée par les modules actuels de HCMO, notamment HCMO-bio, HCMO-housing, HCMO-env et HCMO-tech. Cela permet de justifier le statut de V1 : le modèle n'est pas finalisé, mais il couvre déjà les grands besoins identifiés.

4.4 Caractéristiques de HCMO et usages prévus

TABLE 1 – Caractéristiques principales de la version actuelle de HCMO.

Élément	Nombre
Classes propres à HCMO	environ 45
Propriétés propres à HCMO	environ 46
Classes réutilisées	6
Propriétés réutilisées	17
Préfixes déclarés	12

Ces chiffres donnent une idée de la taille du modèle et de la part de ressources déjà réutilisées. On peut situer HCMO comme une ressource partageable, dans une logique proche des critères attendus pour les ressources ontologiques publiables dans la communauté du Web sémantique, par exemple dans des conférences comme ISWC.

À ce stade, HCMO ne dispose pas encore d'un dépôt public ni d'un point d'accès SPARQL. Ces éléments relèvent plutôt des prochaines étapes : publier le fichier OWL/Turtle, documenter l'ontologie, fournir des exemples d'instances, puis proposer des requêtes SPARQL correspondant aux questions de compétence.

L'ontologie vise également à être utilisée pour répondre à des besoins concrets. Les questions de compétence peuvent être vues comme une première forme de besoins utilisateurs. Certaines d'entre elles pourront ensuite être

traduites en requêtes SPARQL. Par exemple, une requête pourrait permettre d'identifier les animaux hébergés dans une cage donnée, de retrouver les capteurs associés à une enceinte, ou de détecter des observations numériques sans unité. Cette partie “in-use” devra être développée dans les prochaines versions du rapport à partir d'exemples d'instances et de requêtes.

4.5 Construction de l'ontologie

La construction de l'ontologie s'est faite progressivement. Le modèle complet étant trop dense pour être lu directement, il a été séparé en plusieurs vues thématiques. Cette séparation ne correspond pas à des ontologies indépendantes, mais à des vues de travail. Elle permet de rendre le modèle plus lisible et de mieux discuter chaque partie.

Les vues retenues couvrent les principales dimensions du domaine : les métadonnées et les préfixes, le sujet animal, l'hébergement, l'environnement, les observations environnementales et l'acquisition technique. Ce découpage reprend la logique générale du HCM : un animal est observé dans un environnement donné, avec des dispositifs techniques qui produisent des observations, des mesures et des résultats.

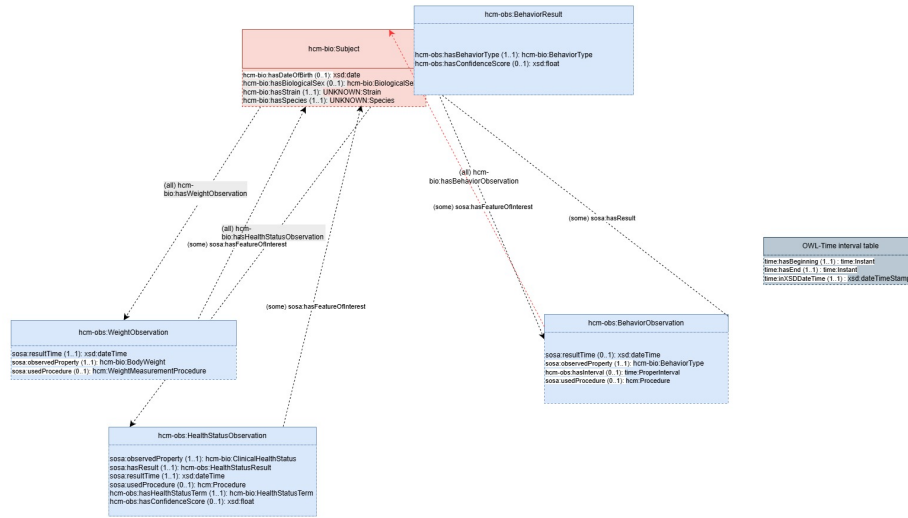


FIGURE 7 – Vue provisoire du module HCMO-bio, centré sur le sujet animal et les observations biologiques.

Le module HCMO-bio, présenté en figure 7, prend la classe `hcm-bio:Subject` comme point central. Celle-ci est reliée aux observations de poids, de santé et de comportement, tandis que les résultats comportementaux sont représentés séparément des événements d'observation. Le modèle conserve ainsi le sujet concerné, la propriété observée, le moment de l'observation, la procédure utilisée et, lorsqu'il existe, le résultat associé.

4.6 Description des classes et relations

Le module HCMO-housing, présenté en figure 8, relie le sujet, son groupe expérimental et l'enceinte dans laquelle il est hébergé. La classe `HousingAssignment` permet de représenter cette assignation dans le temps, plutôt que de considérer l'appartenance à une cage comme une propriété permanente. Les relations avec les groupes et les facteurs d'étude replacent également l'hébergement dans le contexte du protocole expérimental.

02 - Hébergement, cage et contexte expérimental

Vue reliant l'animal à son assignation, son groupe, la cage et les facteurs d'étude.

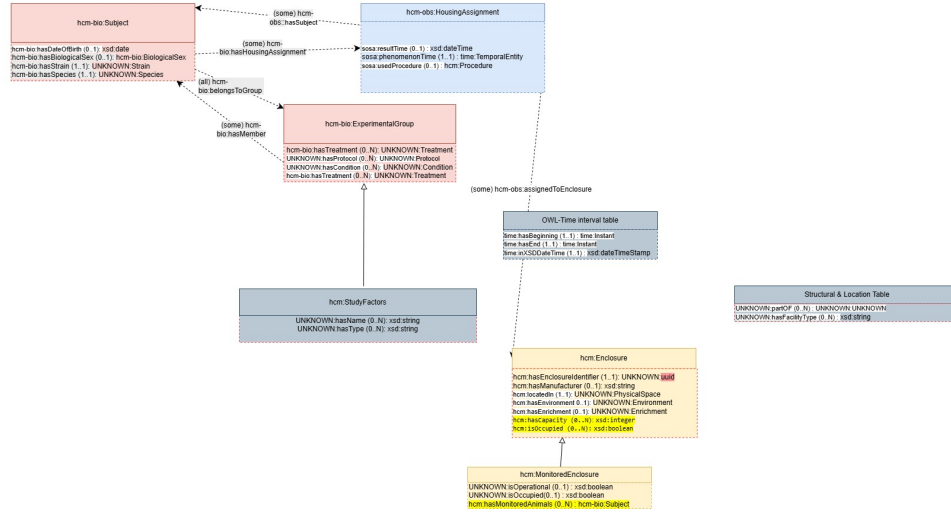


FIGURE 8 – Vue provisoire du module HCMO-housing, centré sur l'hébergement, la cage et le contexte expérimental.

Le module HCMO-env, présenté en figure 9, associe l'enceinte à un profil environnemental regroupant notamment ses dimensions, son cycle lumineux et ses spécifications de mesure. Les propriétés environnementales, comme la température, l'humidité ou les concentrations gazeuses, sont distinguées des valeurs qui les décrivent. Cette séparation permet d'associer à une même propriété différentes observations quantitatives ou catégorielles.

La figure 11 résume cette logique de modélisation sous une forme simplifiée.




FIGURE 11 – Schéma simplifié de la chaîne de modélisation HCMO : de l’animal observé au résultat interprété, en conservant le contexte et la provenance.

Un choix important de modélisation a été de ne pas confondre le capteur, l’observation et le résultat. Le capteur est un dispositif technique. L’observation correspond à l’acte ou à l’événement de mesure, situé dans un contexte donné. Le résultat correspond à la valeur ou à l’interprétation produite. Cette séparation permet par exemple de représenter qu’un capteur donné a produit une observation, que cette observation concerne une propriété particulière, et que le résultat possède une valeur, une unité ou éventuellement un niveau de confiance.

Ce choix est utile pour le HCM, car les données produites ne sont pas toujours directement des comportements. Une caméra, un capteur de poids ou un système RFID produit d’abord des signaux ou des mesures. Ces mesures peuvent ensuite être transformées par un logiciel pour inférer un comporte-

ment, une activité ou un état physiologique. L'ontologie doit donc conserver cette chaîne entre dispositif, observation, mesure et interprétation.

Les relations entre ces classes permettent de représenter la logique générale du domaine. Un animal vit dans une cage, une cage peut être surveillée par un système, un système contient des capteurs, un capteur produit des observations, et ces observations sont associées à des mesures ou à des résultats. L'intérêt du modèle est donc de conserver le lien entre la donnée et son contexte de production.

5 Discussion et perspectives

Le modèle proposé reste une première version de travail. Ce statut de V1 ne signifie pas que HCMO est une ontologie finalisée. Il correspond plutôt à un premier état stabilisé : les grands modules sont identifiés, une partie importante des questions de compétence peut être représentée, et les premières vues ont été discutées avec des experts du domaine. Ce travail s'appuie notamment sur les échanges avec Damien Huzard et sur un groupe de travail lié au réseau COST TEATIME, incluant notamment Benoît Petit-Demoulière, Davor Virag et Vootele Voikar. Ces échanges permettent de confronter la modélisation à des besoins réels du domaine HCM, plutôt que de construire une ontologie uniquement à partir d'une lecture théorique.

Une première limite concerne le niveau de maturité du modèle. HCMO permet déjà de représenter les grandes familles du domaine : sujet animal, hébergement, environnement, observations, acquisition technique et méta-données. Cependant, certaines frontières restent encore difficiles à stabiliser. C'est notamment le cas entre donnée brute, mesure traitée, observation interprétée et résultat biologique. Dans un contexte HCM, une même information peut être vue comme une donnée produite par un capteur, comme une observation contextualisée, ou comme un résultat déjà interprété par un logiciel. Cette distinction devra être précisée dans les prochaines versions.

Une deuxième limite concerne la diversité des systèmes HCM. Certains systèmes reposent sur la vidéo, d'autres sur la RFID, des capteurs de mouvement, des capteurs de poids, des systèmes de suivi de consommation ou des dispositifs physiologiques. Il est donc difficile de produire un modèle unique qui couvre tous les cas sans devenir trop général. HCMO doit rester assez large pour être réutilisable, mais assez précis pour décrire correctement les expériences. Cet équilibre reste un point de vigilance.

Certains éléments ont aussi été volontairement laissés de côté ou peu détaillés dans cette première version. C'est le cas des pathologies précises, des traitements expérimentaux complexes, des analyses statistiques avancées et

des modèles d'intelligence artificielle appliqués aux données. Ces dimensions sont importantes, mais les intégrer trop tôt aurait rendu le modèle plus difficile à stabiliser. La priorité de cette V1 a donc été de représenter correctement la chaîne principale : sujet animal, environnement, système d'acquisition, observation, mesure, résultat et métadonnées.

Une troisième limite concerne l'alignement avec des ontologies et vocabulaires existants. La V1 utilise déjà certains standards ou vocabulaires comme SOSA, OWL-Time ou UO, mais cet alignement reste encore partiel. Les prochaines étapes devront vérifier plus systématiquement quels concepts doivent être réutilisés tels quels, lesquels doivent être spécialisés, et lesquels doivent rester propres à HCMO. Ce point est important pour éviter de créer une ontologie isolée, difficile à connecter à d'autres ressources.

L'intérêt principal d'une ontologie ne se limite pas à organiser les données. Elle peut aussi permettre de raisonner sur ces données. Un premier niveau de raisonnement est classique : vérifier qu'une observation possède une unité, qu'un animal est bien associé à une cage sur un intervalle de temps, ou qu'une mesure environnementale est reliée à un capteur. Ce type d'inférence peut aider à détecter des incohérences ou des métadonnées manquantes.

Un second niveau concerne l'utilisation de l'ontologie avec des méthodes d'intelligence artificielle. Dans ce cas, HCMO peut servir de cadre pour contraindre l'interprétation des données. L'idée n'est pas de laisser un modèle d'IA proposer librement des relations, mais de lui fournir une structure explicite du domaine : quelles entités existent, quelles relations sont possibles, quels contextes sont nécessaires pour interpréter une mesure. L'ontologie peut donc aider à rendre les analyses plus contrôlées, plus explicables et plus compatibles avec les besoins FAIR.

La construction de HCMO peut aussi être replacée dans une logique proche de LOT. Le travail a commencé par l'identification des besoins et des questions de compétence, puis par la construction progressive du modèle à partir de ces besoins. La version actuelle peut être rapprochée d'un état préliminaire de release candidate au sens de LOT : elle n'est pas encore stable ni publiée, mais elle est suffisamment structurée pour être évaluée, discutée et corrigée avec les experts du domaine.

L'évolution de HCMO devra être évaluée à plusieurs niveaux. Un premier niveau concerne la satisfaction des besoins utilisateurs, à travers les questions de compétence et les retours des experts du domaine. Un deuxième niveau concerne des mesures plus quantitatives : nombre de questions couvertes, nombre de classes et de propriétés, proportion de concepts alignés avec des vocabulaires existants, ou encore nombre d'erreurs détectées par des outils de validation. Enfin, une évaluation plus pratique devra vérifier si l'ontologie permet réellement de produire des annotations utiles, interrogeables et

réutilisables dans des cas d’usage HCM.

La suite du travail portera surtout sur la documentation, les cas d’usage concrets, l’ajout d’instances et l’alignement avec d’autres vocabulaires ou ontologies. À plus long terme, HCMO pourrait servir de base à une meilleure annotation des jeux de données HCM, faciliter leur comparaison entre laboratoires et soutenir des démarches d’analyse plus avancées, y compris avec des outils d’intelligence artificielle.

Références

- [1] Haonan Bian. LLM-empowered knowledge graph construction : A survey, October 2025. arXiv :2510.20345 [cs].
- [2] Elliot Hugo Butz, Jérôme Azé, Konstantin Todorov, Antoine Toffano, and Pierre Larmande. Leveraging ontology structure for machine learning in knowledge graphs.
- [3] Maria Assunta Cappelli and Giovanna Di Marzo Serugendo. Methodological Exploration of Ontology Generation with a Dedicated Large Language Model. *Electronics*, 14(14) :2863, July 2025.
- [4] Serge Ch’avez-Feria, Ra’ul Garc’ia-Castro, and Mar’ia Poveda-Villal’on. Chowlk : From uml-based ontology conceptualizations to owl. In Paul Groth, Maria-Esther Vidal, Fabian Suchanek, Pedro Szekely, Pavan Kanipathi, Catia Pesquita, Hala Skaf-Molli, and Minna Tamper, editors, *The Semantic Web – 19th International Conference, ESWC 2022*, volume 13261 of *Lecture Notes in Computer Science*, pages 338–352, Cham, 2022. Springer.
- [5] Mike Dean and Guus Schreiber. Web Ontology Language, January 2026.
- [6] Daniela Duarte-Domingues, Paul Mieske, Pia Kahnau, Lars Lewejohann, Marion Rivalan, and Davor Virag. Achieving Independence and Precision—A Guide for Do-It-Yourself (DIY) Home Cage Monitoring. In Stefano Gaburro and Silvia Mandillo, editors, *Home Cage Monitoring in Rodents : A Global Effort*, pages 235–266. Springer Nature Switzerland, Cham, 2026.
- [7] Hamish Forrest, Damien Huzard, Leonardo Restivo, Szczepan W. Baran, and Benoit Petit-Demoulière. Data sharing and metadata. In Stefano Gaburro and Silvia Mandillo, editors, *Home Cage Monitoring in Rodents : A Global Effort*, pages 267–300. Springer Nature Switzerland, Cham, 2026.

- [8] Aldo Gangemi, Carola Catenacci, Massimiliano Ciaramita, and Jos Lehmann. Modelling Ontology Evaluation and Validation. In David Hutchison, Takeo Kanade, Josef Kittler, Jon M. Kleinberg, Friedemann Mattern, John C. Mitchell, Moni Naor, Oscar Nierstrasz, C. Pandu Rangan, Bernhard Steffen, Madhu Sudan, Demetri Terzopoulos, Dough Tygar, Moshe Y. Vardi, Gerhard Weikum, York Sure, and John Domingue, editors, *The Semantic Web : Research and Applications*, volume 4011, pages 140–154. Springer Berlin Heidelberg, Berlin, Heidelberg, 2006. Series Title : Lecture Notes in Computer Science.
- [9] Daniel Garijo. WIDOCO : A Wizard for Documenting Ontologies. In Claudia d’Amato, Miriam Fernandez, Valentina Tamma, Freddy Lecue, Philippe Cudré-Mauroux, Juan Sequeda, Christoph Lange, and Jeff Heflin, editors, *The Semantic Web – ISWC 2017*, volume 10588, pages 94–102. Springer International Publishing, Cham, 2017. Series Title : Lecture Notes in Computer Science.
- [10] Matthew Horridge. A Practical Guide To Building OWL Ontologies Using Prote´ge´ 4 and CO-ODE Tools Edition 1.2.
- [11] Damien Huzard, Christopher K. Adams, Julio Alvarez, Michael Florea, Stefano Gaburro, Thomas Lorimer, Paul Mieske, Matt Ruiter, Oliver Sturman, Noah Weber, and Davor Virag. Technologies for home cage monitoring in preclinical research. In Stefano Gaburro and Silvia Mandillo, editors, *Home Cage Monitoring in Rodents : A Global Effort*, pages 171–210. Springer Nature Switzerland, Cham, 2026.
- [12] Anna Kiryk, Aleksandra Bartelik, Sara Wells, and Hilary Gates. Home cage monitoring : Where we are and what we need ? In Stefano Gaburro and Silvia Mandillo, editors, *Home Cage Monitoring in Rodents : A Global Effort*, pages 1–42. Springer Nature Switzerland, Cham, 2026.
- [13] Sierra Moxon, Harold Solbrig, Deepak Unni, Dazhi Jiao, Richard Bruskievich, James Balhoff, Gaurav Vaidya, William Duncan, Harshad Hegde, Mark Miller, Matthew Brush, Nomi Harris, Melissa Haendel, and Christopher Mungall. The linked data modeling language (linkml) : A general-purpose data modeling framework grounded in machine-readable semantics. In *Proceedings of the International Conference on Biomedical Ontologies 2021*, volume 3073 of *CEUR Workshop Proceedings*, pages 148–151, 2021.
- [14] Natalya F Noy and Deborah L McGuinness. Ontology Development 101 : A Guide to Creating Your First Ontology.
- [15] Silvio Peroni. A Simplified Agile Methodology for Ontology Development. In Mauro Dragoni, María Poveda-Villalón, and Ernesto Jimenez-Ruiz, editors, *OWL : Experiences and Directions – Reasoner Evaluation*,

- volume 10161, pages 55–69. Springer International Publishing, Cham, 2017. Series Title : Lecture Notes in Computer Science.
- [16] Benoit Petit-Demoulière and Damien Huzard. Data welfare is animal welfare : Building a WellFAIR research ecosystem. *Neuroscience Applied*, 5 :106998, 2026.
 - [17] María Poveda-Villalón, Alba Fernández-Izquierdo, Mariano Fernández-López, and Raúl García-Castro. LOT : An industrial oriented ontology engineering framework. *Engineering Applications of Artificial Intelligence*, 111 :104755, May 2022.
 - [18] María Poveda-Villalón, Mari Carmen Suárez-Figueroa, and Asunción Gómez-Pérez. Validating Ontologies with OOPS! In David Hutchison, Takeo Kanade, Josef Kittler, Jon M. Kleinberg, Friedemann Mattern, John C. Mitchell, Moni Naor, Oscar Nierstrasz, C. Pandu Rangan, Bernhard Steffen, Madhu Sudan, Demetri Terzopoulos, Doug Tygar, Moshe Y. Vardi, Gerhard Weikum, Annette Ten Teije, Johanna Völker, Siegfried Handschuh, Heiner Stuckenschmidt, Mathieu d’Acquin, Andriy Nikolov, Nathalie Aussenac-Gilles, and Nathalie Hernandez, editors, *Knowledge Engineering and Knowledge Management*, volume 7603, pages 267–281. Springer Berlin Heidelberg, Berlin, Heidelberg, 2012. Series Title : Lecture Notes in Computer Science.
 - [19] Gaoussou Sanou, Taciana Manso, Konstantin Todorov, Véronique Giudicelli, Patrice Duroux, and Sofia Kossida. Therapeutic monoclonal antibodies repurposing in oncology via IMGT/mAb-KG embeddings. *BMC Medical Informatics and Decision Making*, 26(1) :89, February 2026.
 - [20] Stanford Center for Biomedical Informatics Research. Protégé 5 Documentation : Getting Started.